

АНАЛИЗ ДАТАСЕТА АО «МОСКОЛЛЕКТОР»

Сервис прогнозирования инцидентов в инженерных коллекторах

Задача №8 «Город»

Конкурс «Лидеры цифровых трансформаций 2026»

Постановщик: Департамент жилищно-коммунального хозяйства города Москвы

Эксплуатант: АО «Москоллектор»

Команда «Дискреция творца»

Москва, сентябрь 2026

Содержание

1. Что физически лежит в датасете	2
Структура парка	2
2. Семантический контракт значений	3
Heartbeat съедает две трети пожарного контура	3
3. Флаг тревожное непригоден как целевая переменная	3
4. Две аномалии, отравляющие любую глобальную метрику	4
4.1. Май 2021, база 847 — 42 % всех тревог датасета	4
4.2. Провалы сбора данных	4
5. Локация: связи «канал → объект» в данных нет	4
Что удалось восстановить	4
Обезличивание неполное	5
6. Ground truth отсутствует полностью	5
7. Сценарии ТЗ: что данные реально поддерживают	5
7.1. Пожар — supervised невозможен	5
7.2. Подтопление — сигнал есть, но не там, где ожидалось	5
7.3. Несанкционированный доступ — правило, а не модель	6
8. Качество данных	6
9. Производительность — требования ТЗ выполняются с запасом	6
10. Файл-пример — готовый holdout из будущего	6

Аудит проведён по 11 независимым измерениям на полном объёме данных (313 546 016 событий). Все числа получены SQL-запросами в DuckDB, ключевые — перепроверены вторым независимым запросом.

1. Что физически лежит в датасете

Файл	Содержимое
ext-journal-2019..2026.csv	313 546 016 событий, 2019-01-01 ... 2026-06-30 (14,8 ГБ)
справочник_каналов_датчиков.csv	11 485 каналов: тип системы, тип датчика, тег, название
справочник_объектов_диспетчер.csv	95 объектов: 1 район → 16 объектов → 78 подобъектов
журнал_событий_пример.csv	ровно одни сутки 2026-08-01, 169 993 события, 1 241 канал
dataset.zip, *.7z	те же 11 файлов, ничего дополнительного

Глубина данных — 7,5 года, а не «не менее 12 лет», как заявлено в п. 13 ТЗ. Дефицит 4,5 года (37,5 %).

Структура парка

6 типов инженерных систем, 19 типов датчиков, 32 «базы» тега:

Система	Каналов	Топ типов датчиков	Каналов
Пожарная охрана	5 701	Датчик дыма	4 337
Диспетчерский контроль	2 364	Состояние фазы	957
Охранная подсистема	2 211	КД Дверь	917
Температурная подсистема	600	Датчик движения	804
Газовая охрана	529	Переключатель	801

Система	Каналов	Топ типов датчиков	Каналов
Диагностическая подсистема	80	Состояние УИР-Р	762

2. Семантический контракт значений

Словарь выглядит как 49 942 уникальных значения, но это ложная сложность:

- **32 текстовых состояния** — 88 325 751 событие (28,17 %)
- **1 761 числовое значение** — 225 088 757 (71,79 %)
- **48 149 строк-дат** — 131 508 (0,042 %), мусор

Построен контракт (тип_датчика, значение) → семантический класс с покрытием **100,0000 %** объёма:

Класс	Событий	Доля
ТЕЛЕМЕТРИЯ_ЧИСЛО	223 391 028	71,25 %
НОРМА	44 025 573	14,04 %
СРАБОТКА	34 796 394	11,10 %
НЕОПРЕДЕЛЕНО	7 503 339	2,39 %
МУСОР	1 829 237	0,58 %
ОТКАЗ	1 768 150	0,56 %
ОТКЛЮЧЕНО	232 295	0,07 %

Классы идеально отделяют тревожность: у НОРМА, НЕОПРЕДЕЛЕНО, ТЕЛЕМЕТРИЯ_ЧИСЛО и МУСОР доля тревожное=true равна **ровно 0 %** во все 8 лет. Это таблица на 32 строки — её место в коде, а не в модели.

Heartbeat съедает две трети пожарного контура

Пара Норма ↔ Неопределен — не показания датчика, а сигнал потери/восстановления связи:

- у «Тепловой датчик» она составляет **99,22 %** всего объёма (497 138 из 501 064) при соотношении 1,015
- матрица переходов за 2023: 7 906 Неопределен→Норма и 7 471 Норма→Неопределен против **191** реальной сработки
- медиана эпизода — **5 секунд**, 79,3 % короче минуты

Доля heartbeat: Состояние УИР-Р 94,94 %, КД Люк 89,13 %, Ручной извещатель 70,22 %, Датчик дыма 61,96 %.

Следствие: без дебаунса (схлопывание эпизодов < 60 с) любой счётчик событий завышен в разы.

3. Флаг тревожное непригоден как целевая переменная

Всего 2 467 812 тревог = 0,787 % событий. Тревожными бывают ровно 16 значений, и **ни одно не даёт 100 %**.

Флаг дрейфует во времени. Для неизменного значения Обнаружен дым доля тревожных:

2019	2020	2021	2022	2023	2024	2025	2026
34,1 %	49,5 %	15,3 %	12,3 %	7,1 %	10,0 %	30,4 %	100 %

Флаг не является функцией от (канал, значение). 22 150 троек (канал, значение, год) содержат одновременно true и false — это 24,68 млн событий и 526 267 тревог (21,33 % всей положительной раз-

метки). Значит флаг зависит от чего-то, чего в данных нет: режим охраны, квитирование оператором, наряд на ТО.

Вывод: как таргет не используем. Тревожность пересобираем из контракта (тип_датчика, значение).

4. Две аномалии, отравляющие любую глобальную метрику

4.1. Май 2021, база 847 — 42 % всех тревог датасета

77 дымовых каналов базы 847 выдали **1 035 783 тревоги** Неисправен за 54 суток (30.04–07.06.2021):

- ≈ 478 тревог на канал в сутки, одна каждые 3 минуты непрерывно неделями
- почасовой профиль **плоский** (41 970–43 882 по часам, размах 4,5 %) — машина, не человек
- разброс между каналами 1,5 % — синхронный дребезг шлейфа
- в 2022 та же пара каналов дала 800 событий

Это 41,97 % всех тревог за 7,5 лет из одного объекта за три месяца.

4.2. Провалы сбора данных

- 2024-04-06 ... 2024-04-09 — 76,5 ч, двое суток полностью нулевые
- 2026-06-01 — сутки полностью отсутствуют

Следствие: случайный train/test split невозможен. Только группировка по (база, месяц) и временной сплит.

5. Локация: связи «канал → объект» в данных нет

РАЗДЕЛ УСТАРЕЛ. В обновлении датасета от 16.09.2026 организаторы добавили в справочник каналов колонку `ид_объект` — покрытие 100 % каналов и 96,99 % событий журнала. Выводы ниже описывают состояние до обновления; методика и её проверка сохранены, потому что независимая реконструкция **точно совпала** с официальными данными. Актуальное состояние — [05-обновление-dataseta.md](#).

Прямого внешнего ключа не существует. Обещанный ТЗ тег формата `МК-1.1.1.1.1.1` отсутствует: 0 из 11 485 тегов имеют префикс МК-, все 11 485 имеют вид `847-1.1.56.63`. с **переменной глубиной** (5 сегментов — 92,4 %, 6 — 5,1 %, 4 — 2,4 %, 2 — 0,16 %).

Три метода восстановления проверены и **провалены на эталоне**:

Метод	Результат
Греческие имена объектов	0 совпадений из 20 в названиях датчиков
Диапазоны пикетов	один ПК встречается в 3–4 базах; Жаккар для эталонной пары 885–890 = 0,106
Корреляция суточной активности	для эталонной пары 885–890 $r = 0,133$ (26-е место из 31)

Причина провала последнего метода физична: базы одного объекта **специализированы** — 890 это ОПС (341 пожарный канал, 0 газовых), 885 это ДУ/газ (90 диспетчерских, 38 газовых, 0 пожарных). Их суточные профили противоположны, а не похожи.

Что удалось восстановить

- **база 847 = объект Кси** (эталон): каналы `847-g1`. «к-р Комунарка ПК0–ПК202» дословно совпадают с объектом 5332
- **базы 885 + 890 = объект Дзета**: строка «ПК48 Г1 ПК5» встречается ровно в этих двух базах и в объекте 5594

Итоговое покрытие: имя объекта доступно для **17,6 %** каналов. Устойчивая пара (база, ПК) — для **92,6 %**.

Обезличивание неполное

В названиях датчиков уцелел **31 реальный московский топоним** по 16 базам: Зюзино, Ясенево, Беляево, Коньково, Коммунарка, Вавиловский, Ленинский 131, Гарибальди, Никулино, Н. Черёмушки, Академическая. Связать топоним с греческим `ид_объект` нельзя — именно эту связь уничтожило обезличивание.

6. Ground truth отсутствует полностью

Поиск по 10 корням (ложн, подтвержд, выезд, бригад, отмен, квитир, сброс, обработ, диспетч, провер) по всему словарю значений дал **0 строк и 0 событий**. Все 8 файлов журнала имеют ровно 6 колонок.

Нет: журнала инцидентов, решений диспетчера, справочника причин, заявок, нарядов, актов, выездов.

7. Сценарии ТЗ: что данные реально поддерживают

7.1. Пожар — supervised невозможен

- Обнаружен дым — 164 288 событий, срабатывали **все 4337** дымовых каналов без исключения (медиана 28 на канал)
- **96,1 % тревог пожарной подсистемы — это неисправности, а не пожары:** на дымовых каналах 1 124 758 тревог Неисправен против 42 433 Обнаружен дым
- после отсева прогонов ТО и требования локальности остаётся **11 кандидатов** «дата × пикет» за 8 лет, минимум 4 из них — групповой обход
- термическое подтверждение структурно недоступно: тепловые датчики есть только на **3 базах из 24**, лишь 242 пикета из 2549 (9,5 %) имеют и дым, и термику
- температура опрашивается с медианным интервалом **184 минуты** — реальное возгорание система не увидит
- ручные извещатели: Рычаг сдернут встречается 189 раз на 8 каналах с интервалом ~47 дней и полностью прекращается 25.06.2021 — это учебные проверки, человеческого подтверждения пожара в данных нет ни разу

7.2. Подтопление — сигнал есть, но не там, где ожидалось

Затоплен у насосов — это не вода, а бит слова неисправности:

- 97,5 % событий (60 727 из 62 285) приходят в пределах ≤ 5 с от предыдущего, медианный интервал 0 с
- цепочка жёсткая: в 85,6 % случаев предшествует Неисправен, в 65,1 % следует Обесточен
- сезонный пик в **августе**, а не в паводок

Датчики затопления (25 шт.) бесполезны: 12 424 события за 8 лет (0,004 % журнала), значений Затоплен / Замкнут нет **ни одного**, а Не замкнут имеет медианную и p90 длительность 0 минут — дребезг.

Что работает — счётчик пусков насосов:

- 505 118 переходов Выключен–Включен, лог чистый (только 0,88 % повторов значения)
- база: медиана 2 пуска/сутки на активных сутках, p75 = 7, p95 = 28, p99 = 87, максимум 1777
- **норма у каждого насоса своя:** личные медианы от 1 до 45 пусков/сутки
- сезонность сильная и воспроизводится все 8 лет: март + апрель = **38,3 %** пусков на 16,4 % суток

- 68 суток за 8 лет с ≥ 10 синхронно нагруженными насосами: март 38, апрель 15, сентябрь–декабрь 0

7.3. Несанкционированный доступ — правило, а не модель

- 9 баз из 32 находятся «под охраной» 98,2–99,9 % всего времени (база 414 — 99,87 % при 55 интервалах за 8 лет). Это залипший канал, а не режим объекта
- на 9 «чистых» базах за 2025 год — 339 эпизодов срабатываний под охраной, из них 4 мультисенсорных ночных
- нагрузка на диспетчера 0,93 сигнала в сутки

8. Качество данных

Проблема	Масштаб
ид_события не первичный ключ	6 026 078 лишних строк (1,92 %); 3 792 870 id переиспользованы между годами
Каналы без паспорта	1 142 канала журнала (9,04 %) нет в справочнике; 9 439 854 события, 151 740 тревог
Перекося базы 797	52,1 % всего журнала; из них 49,8 % датасета дают 55 газовых датчиков (период опроса 68 с)
Мусор в значениях	83 054 события 01.01.1970 03:00:0x — сломанный timestamp в поле значения
Сентинелы температуры	–127 (8 138 записей, код ошибки DS18B20), –3276, 999
Повторный заголовок	в ext-journal-2025.csv в середине файла (строка 26 140 585)
Переводы строк в справочнике	9 записей с \n внутри поля названия; файл в CRLF

Обратной проблемы нет: все 11 485 каналов справочника встречаются в журнале.

9. Производительность — требования ТЗ выполняются с запасом

Измерено, а не задекларировано:

Операция	Факт	Лимит ТЗ	Запас
Inference одного объекта (база 847, 1459 каналов)	0,05 с	300 с	×6000
Срез сырого журнала за 24 ч по объекту	0,04 с	—	—
Поток событий (2026)	1,97 соб/с, пик 2,66	—	—

Поток в 2 события/секунду снимает вопрос о Kafka — достаточно батча раз в минуту.

10. Файл-пример — готовый holdout из будущего

журнал_событий_пример.csv — это не образец формата, а **типичные сутки 2026-08-01, лежащие на 32 дня позже конца обучающих данных (2026-06-30)**:

- 169 993 события против среднесуточных 170 530 за 2026 год — типичные сутки, не выборка
- 1 241 канал, 207 тревог, дублей ид_события — 0, каналов без паспорта — 0

Это закрывает требование раздела 18 ТЗ «проверка прогнозирования путём сравнения реальных данных и прогнозных значений»: обучаемся по 2026-06-30, прогнозируем, заливаем файл как живой поток, сравниваем.