

ВОПРОСЫ ОРГАНИЗАТОРАМ И РАСХОЖДЕНИЯ С ТЗ

Сервис прогнозирования инцидентов в инженерных коллекторах

Задача №8 «Город»

Конкурс «Лидеры цифровых трансформаций 2026»

Постановщик: Департамент жилищно-коммунального хозяйства города Москвы

Эксплуатант: АО «Москоллектор»

Команда «Дискреция творца»

Москва, сентябрь 2026

Содержание

A. Расхождения схемы данных с Приложением 1 ТЗ	2
A1. Журнал: расходятся 3 поля из 5	2
A2. Реестр типов каналов — отсутствует как сущность	3
A3. Тег в дереве объектов — формат не тот и связь отсутствует	3
A4. Дерево объектов не соединяется с каналами	3
B. Критические вопросы — влияют на постановку задачи	3
C. Вопросы по семантике — влияют на корректность вердикта	4
D. Вопросы по инфраструктуре данных	5
E. Требования ТЗ, невыполнимые на предоставленных данных	5
F. Метрики качества при отсутствии ground truth	6

Статус на 16.09.2026: обновление датасета закрыло вопрос № 4 (связь канал → объект) и сняло № 16 (топонимы). Остальные 18 актуальны. См. [05-обновление-датасета.md](#).

Аудит выявил 89 блокеров. Ниже они сведены в 18 вопросов, сгруппированных по приоритету. Для каждого указан **план Б** — что делаем, если ответа не будет. Работа не блокируется ни по одному пункту.

A. Расхождения схемы данных с Приложением 1 ТЗ

ТЗ описывает четыре сущности. Ни одна не совпадает с фактической.

A1. Журнал: расходятся 3 поля из 5

ТЗ (Приложение 1)	Факт	Статус
ИД записи журнала	ид_события	не первичный ключ — 6 026 078 дублей (1,92 %)
ИД канала данных	ид_канала_данных	совпадает
ИД типа канала данных	—	отсутствует полностью
Текущее значение (25,00)	значение_датчика VARCHAR	28,21 % нечисловые; разделитель точка, не запятая
Дата записи (единый datetime)	дата + время	расщеплено на два поля
—	тревожное BOOLEAN	появилось поле, которого нет в ТЗ

Вопрос 1. Почему в журнале нет «ИД типа канала данных»? Для 1 142 каналов (9 %) тип недостижим даже через join, потому что их нет в справочнике.

План Б: все типозависимые правила получают ветку «тип неизвестен»; в UI такие каналы помечаются статусом «канал без паспорта».

Вопрос 2. ид_события не уникален: 3 792 870 идентификаторов переиспользованы **между годами**. Пример: event_id=1555467403 — это одновременно (канал 3077, 2019-08-26 07:33:25, «Движения нет») и (канал 196789, 2020-12-04 22:58:20, «0.01»). Это сквозной счётчик АСУ ТП или ошибка выгрузки?

План Б: PRIMARY KEY (ид_события) в PostgreSQL молча потеряет 1,92 % строк, причём неравномерно по годам (2021 и 2023 пострадают, 2025 — нет), создав искусственный тренд. Ключ делаем составным: (ид_события, дата, время, ид_канала_данных), дедуп по (канал, дата, время, значение, тревожное).

А2. Реестр типов каналов — отсутствует как сущность

ТЗ обещает справочник с числовыми id (2 = contact-unlock-norm, 4 = smoke, 6 = gas, 12 = temperature...). Фактически — 19 текстовых значений `тип_датчика`. Маппятся 8 из 9. Тип 2 расщеплён на 5 разных (КД Дверь, КД АВ, КД Люк, 9-секционный люк, Стекло). Не имеют аналога в ТЗ 6 типов: Состояние УИР-Р (762 канала), Тепловой датчик (472), Ручной извещатель (130), ИБП (80), Состояние охраны (47).

Вопрос 3. Будет ли предоставлен реестр типов с числовыми id?

План Б: публикуем его сами по номенклатуре ТЗ + словарь маппинга 19 → 9 + 6. Это закрывает требование интеграции (разд. 17 п. 2), а не прячет разрыв.

А3. Тег в дереве объектов — формат не тот и связь отсутствует

ТЗ обещает МК-1.1.1.1.1.1 (6 фиксированных уровней). Факт: 847-1.1.56.63. — 0 из 11 485 тегов имеют префикс МК-, глубина **переменная** (5 сегментов у 92,4 %, 6 у 5,1 %, 4 у 2,4 %, 2 у 0,16 %).

А4. Дерево объектов не соединяется с каналами

Из 32 баз тега ровно 1 численно совпадает с `ид_объект` — это уровень случайности. Эталонно установленные базы 847/885/890 среди `ид_объект` вообще отсутствуют. Корневая запись 5773 ссылается на родителя 3831, которого в файле нет — дерево является фрагментом.

В. Критические вопросы — влияют на постановку задачи

ЗАКРЫТ обновлением датасета 16.09.2026 — колонка `ид_объект` добавлена, покрытие 96,99 % событий. Подробности: [05-обновление-датасета.md](#).

Вопрос 4 (главный). Нужна таблица соответствия «база тега / контроллер → `ид_объект`». В боевой SCADA она заведомо есть — её потеряло обезличивание.

Обоснование: три метода восстановления проверены и провалены на эталоне (см. анализ, разд. 5). Имя объекта доступно только для 17,6 % каналов.

План Б: единицей локации принимаем пару (**база тега, ПК**) — покрытие 92,6 %. В вердикте пишем «база 847, ПК231», а не «объект Кси». Карта заменяется линейной схемой коллектора (ось X = пикет) — это и есть реальная система координат эксплуатационника («участок работ» по глоссарию ТЗ).

Вопрос 5. Что физически означает `тревожное`: превышение уставки на приборе, попадание события в журнал тревог АРМ, или факт квитирования диспетчером? Когда менялись правила его выставления?

Обоснование: для `Обнаружен дым` доля тревожных — 7,1 % в 2023 и 100 % в 2026. Флаг не является функцией от (канал, значение): 22 150 троек содержат одновременно true и false.

План Б: трактуем как «реакция АРМ», не как «опасность». Как **таргет** не используем ни в каком виде. Как признак — только в форме агрегата за окно, вместе с признаком года.

Вопрос 6. Был ли 30.04–07.06.2021 на базе 847 реальный инцидент, плановые работы или отказ шлейфа?

Обоснование: 1 035 783 тревоги `Неисправен` за 54 суток с плоским почасовым профилем (размах 4,5 %). Это 42 % всех тревог датасета.

План Б: помечаем окно как технический артефакт и исключаем из обучения и из расчёта базлайнов. Дополнительно вносим его в регрессионный тест: корректная модель обязана классифицировать это как отказ шлейфа, а не как пожар.

Вопрос 7. `Затоплен` у насосов — это затопленный приямок или бит слова неисправности контроллера?

Обоснование: 97,5 % событий в пределах 5 с от предыдущего, цепочка `Неисправен→Затоплен→Обесточен`, сезонный пик в августе вместо паводка.

План Б: не используем как таргет подтопления. Таргет — аномалия частоты пусков; Затоплен становится признаком деградации оборудования, и в вердикте пишется «канал сообщил код неисправности», а не «обнаружена вода».

Вопрос 8. Что означает Не замкнут у датчика затопления и почему в словаре нет Замкнут / Затоплен?

Обоснование: 3 726 тревог при медианной и p90 длительности 0 минут; пики в июле и октябре, а не в паводок; из 335 суток-баз с такой тревогой лишь 6 совпали с «горячим» днём насоса.

План Б: исключаем все 25 каналов из признаков модели подтопления, оставляем только как признак «оборудование установлено».

Вопрос 9. Есть ли выгрузка из АРМ диспетчера: время создания карточки, время квитирования, отметка «выезд / без выезда», классификатор закрытия? Хотя бы за 3–6 месяцев.

Обоснование: ground truth отсутствует полностью. Метрику ТЗ «снижение ложных срабатываний» невозможно измерить прямо — нельзя посчитать ни precision, ни recall подавления.

План Б: реализуем справочник причин и форму фиксации решения в нашем сервисе (таблицы decision, reason_ref). Это одновременно закрывает требование ТЗ (разд. 12, шаг 5) и создаёт механизм накопления разметки с первого дня. В демо заполняем вручную на 20–30 кейсах, показывая жюри замкнутый цикл дообучения.

Вопрос 10. Нужен график ППР (плановых работ) хотя бы за 2024–2025 по объектам и датам.

Обоснование: 86,19 % отказных канал-суток приходятся на массовые базо-дни, 85 % из них — в рабочие часы 09–18, и только 5,74 % в выходные (при доле выходных в календаре 28,6 %). Без внешнего признака «на объекте шли работы» модель с таргетом «отказ завтра» будет предсказывать график бригад, а не состояние оборудования.

План Б: строим прокси прямо из данных — «массовый базо-день» = ≥ 20 каналов базы в отказе ИЛИ ≥ 50 % каналов базы, в рабочие часы будня. Контроль качества фильтра: доля выходных среди оставшихся позитивов должна приблизиться к 28,6 %. В интерфейсе называем нейтрально «массовая синхронная сработка группы», а не «ТО», и показываем состав группы диспетчеру.

С. Вопросы по семантике — влияют на корректность вердикта

Вопрос 11. Единицы измерения и аварийный порог газового датчика. Значения: p50 = 0,01, p95 = 0,09, p99 = 0,20, максимум 10,23 (= 1023/100, предел 10-битного АЦП). Похоже на % НКПР, но текстовое Обнаружен газ приходит с отдельного дискретного выхода и не коррелирует с числом.

План Б: работаем в безразмерных перцентилях сети: фон $\leq 0,10$, повышенное 0,10–0,20, аномалия $> 0,20$. В вердикте формулируем относительно: «0,45 — выше 99-го перцентиля по всем газовым каналам сети».

Вопрос 12. Что такое Неопределен (7,50 млн событий, 12 566 каналов, до 6 638 каналов за одни сутки)? Потеря связи АРМ с контроллером, рестарт сервера или штатный статус опроса?

План Б: исключаем из таргета (таргет = Неисправен / Обесточен / Отключено устройство). Оставляем как сетевую ковариату уровня базы. Как поканальный предиктор доказанно слаб — lift 1,28×.

Вопрос 13. Почему у пары (Состояние фазы, Обесточен) за 8 лет ноль тревог при 1 064 438 событиях на 953 каналах? У насосов то же значение даёт 88,9 % тревог.

План Б: включаем в контракт как ALARM, но с обязательным дебаунсом и счётом эпизодов, а не отдельных событий.

Вопрос 14. Является ли Обесточен у типа Состояние фазы отказом или штатным режимом? 107 из 957 каналов проводят в этом состоянии более половины суток жизни.

Обоснование: этот тип даёт 76,9 % всех позитивов таргета (базовая частота 14,34 % против 0,189 % у дымовых) — он полностью перекосит модель.

План Б: выносим типы Состояние фазы, Состояние насоса, Состояние вентилятора, ИБП, Состояние охраны в отдельную задачу «состояние энергоснабжения». Базовая частота после исключения — 0,093 % на горизонте 24 ч и 0,630 % на 7 суток, что по-прежнему обучаемо.

Вопрос 15. Считается ли Неисправен поводом для выезда бригады, или это заявка на следующий обход?

Обоснование: это 57,82 % всех тревог датасета. От ответа зависит вся экономика метрики.

План Б: считаем две метрики раздельно — «сокращение аварийных карточек» (знаменатель 2,99 % потока) и «сокращение сервисных карточек» (66,5 %). Смешивать нельзя: одна цифра на объединённом знаменателе вводит в заблуждение.

СНЯТ обновлением 16.09.2026 — организаторы сами восстановили реальные названия в 364 строках.

Вопрос 16. Можно ли показывать в интерфейсе уцелевшие топонимы (Зюзино, Ясенево, Коммунарка, Беляево, Коньково, Вавиловский, Ленинский 131)? Обезличивание применено непоследовательно.

План Б: используем как внутренний ключ группировки, в демо выводим обезличенную подпись «база + ПК», чтобы не нарушить условия конкурса.

D. Вопросы по инфраструктуре данных

Вопрос 17. Провалы сбора 2024-04-06...04-09 (76,5 ч) и 2026-06-01 — это реальное отключение сети, плановая миграция или потеря при выгрузке? Были ли частичные потери в другие даты?

План Б: маска доступности: сутки с объёмом < 10 % годовой медианы ИЛИ числом активных каналов < 25 % медианы помечаются NO_DATA, исключаются из обучения и подавляют вердикт «датчик молчит».

Вопрос 18. База 797 (55 газовых каналов) даёт 49,8 % всего датасета с периодом опроса 68 с, тогда как остальные 474 газовых канала опрашиваются раз в 400–1900 с. Это другое оборудование, другая настройка апертуры или шлюз-агрегатор?

План Б: обучаем и калибруем пороги отдельно для базы 797 и для остальных, никогда не смешивая в одной базовой линии. Все сетевые агрегаты делим на число активных каналов.

E. Требования ТЗ, невыполнимые на предоставленных данных

Требование ТЗ	Статус	Что делаем
Глубина данных ≥ 12 лет (разд. 13)	7,5 года	Фиксируем в документации; признаки с многолетним лагом невозможны
Реестр оборудования: люки, вентиляторы, камеры, насосы (разд. 6, 10, 13)	отсутствует	Синтезируем суррогатный реестр (база, ПК, класс) с полем <code>source='derived'</code>
Журнал заявок и их статусы (разд. 6, 7)	отсутствует	Реализуем свои таблицы заявок; интеграцию описываем контрактом API
Решения диспетчера + справочник причин (разд. 12)	отсутствует	Реализуем в сервисе — это и есть механизм накопления разметки
Метеоданные (разд. 12, 13)	отсутствует	Эндогенный прокси <code>n_hot_channels_today</code> ; вердикт «общесетевой водоприток» без называния причины
Геоданные GeoJSON/WKT, интерактивная карта (разд. 7, 10)	отсутствует	Линейная схема коллектора: ось X = пикет (92,09 % каналов)
График плановых работ (разд. 12)	отсутствует	Детектор массовых синхронных срабаток
Регламентные сроки РТЭК	отсутствует	Рекомендации по состоянию, не по календарю

Важно: ни один из этих пробелов не блокирует работу. Каждый закрывается либо суррогатом на данных, либо реализацией недостающей сущности в самом сервисе — что дополнительно закрывает требование ТЗ.

F. Метрики качества при отсутствии ground truth

ТЗ (разд. 9) оставляет Precision/Recall «на этапе проектирования». Предлагаемый защитимый набор:

1. **Прогноз отказа канала** — честные Precision/Recall/PR-AUC на временном holdout, потому что здесь метки **реальные** (1,5 млн событий Неисправен). Это основная измеримая метрика.
2. **Подавление шума** — «сокращение диспетчерских карточек при 100 % сохранении редких событий»: доля подавленного потока + явный отчёт, что именно подавлено и почему.
3. **Аномалия откачки** — precision@k на ручной экспертной разметке топ-100 суток + «нагрузка на диспетчера» в сигналах/сутки.
4. **Проверка на файле-примере** (2026-08-01) — прогноз строится по данным до 2026-06-30, затем сравнивается с фактом. Это прямо закрывает критерий разд. 18 ТЗ.

Чего **не** делаем: не заявляем ассигасу детектора пожара или проникновения — измерить её не на чем, и на питч-сессии это вскрыется первым же вопросом.