

УТОЧНЯЮЩИЕ ВОПРОСЫ ПО ДАТАСЕТУ И ТЗ

Сервис прогнозирования инцидентов в инженерных коллекторах

Задача №8 «Город»

Конкурс «Лидеры цифровых трансформаций 2026»

Постановщик: Департамент жилищно-коммунального хозяйства города Москвы

Эксплуатант: АО «Москоллектор»

Команда «Дискреция творца»

Москва, сентябрь 2026

Содержание

Блок 1. Критично — влияет на постановку задачи	2
1. Соответствие «база тега → объект» ЗАКРЫТО обновлением от 16.09.2026	2
2. Смысл поля «тревожное»	3
3. Журнал решений диспетчера	3
4. График плановых работ (ППР)	3
5. Событие 30.04 – 07.06.2021 на базе 847	3
Блок 2. Важно — влияет на корректность выводов	4
6. Значение «Затоплен» у каналов типа «Состояние насоса»	4
7. Значение «Не замкнут» у датчиков затопления	4
8. Единицы измерения газовых датчиков	4
9. Значение «Неопределен»	4
10. Статус «Обесточен» у типа «Состояние фазы»	4
11. Режим опроса базы 797	5
Блок 3. Полнота данных	5
12. Глубина данных	5
13. Пропуски в сборе данных	5
14. Каналы без описания	5
15. Реестр оборудования, заявки, метео- и геоданные	5
Блок 4. Расхождения со схемой из Приложения 1 ТЗ	5
16. Структура журнала	5
17. Справочник типов каналов	6
18. Формат тега	6
Блок 5. Организационное	6
19. Обезличивание СНЯТО обновлением от 16.09.2026	6
20. Целевые показатели качества	7

Команда провела полный аудит предоставленных данных (313 546 016 событий, 2019-01-01 ... 2026-06-30) и подготовила вопросы, влияющие на постановку задачи. Работа над решением не остановлена — по каждому пункту принят рабочий вариант, указанный после вопроса. Ответы позволят заменить допущения на факты.

Вопросы отсортированы по влиянию на результат.

Блок 1. Критично — влияет на постановку задачи

1. Соответствие «база тега → объект» ЗАКРЫТО обновлением от 16.09.2026

Колонка `ид_объект` добавлена в справочник каналов, покрытие полное. Вопрос снят, благодарим.

Исходная формулировка

В справочнике каналов теги имеют вид `847-1.1.56.63.` — 32 различных «базы» (число до дефиса). В справочнике объектов 95 записей с `ид\_объект`. ****Связи между ними в данных нет.**** Мы проверили три способа восстановления, все три провалились на контрольном примере: | Способ | Результат | |---|---| | По греческим именам объектов | 0 совпадений из 20 в названиях датчиков | | По диапазонам пикетов | один и тот же ПК встречается в 3–4 базах | | По корреляции суточной активности | для заведомо связанной пары баз 885–890 корреляция 0,133 (26-е место из 31) | Достоверно восстановлено только 17,6 % каналов (база 847 = объект Кси; базы 885 + 890 = объект Дзета). > ****Просим:**** выгрузку соответствия «контроллер / база тега → `ид\_объект`». > В рабочей системе диспетчеризации она заведомо существует — её потеряло обезличивание. > > ****Пока работаем так:**** единица локации — пара (база тега, пикет), покрытие 92,6 %. > В интерфейсе показываем «база 847, ПК231» вместо названия объекта.

2. Смысл поля «тревожное»

Что означает флаг в источнике: превышение уставки на приборе, попадание события в журнал тревог АРМ, или факт квитирования диспетчером? И когда менялись правила его выставления?

Основание для вопроса — флаг нестабилен во времени. Для **одного и того же** значения `Обнаружен дым` доля тревожных записей по годам:

2019	2020	2021	2022	2023	2024	2025	2026
34,1 %	49,5 %	15,3 %	12,3 %	7,1 %	10,0 %	30,4 %	100 %

Кроме того, флаг не является функцией от пары (канал, значение): 22 150 сочетаний «канал + значение + год» содержат одновременно и `true`, и `false` — это 24,68 млн событий.

Просим: описание логики выставления флага и даты изменений (смена ПО, прошивок, настроек АРМ).

Пока работаем так: тревожность пересобираем из пары (тип датчика, значение) по собственному справочнику; исходный флаг как целевую переменную не используем.

3. Журнал решений диспетчера

В данных отсутствует информация об исходе событий. Поиск по корням `ложн`, `подтвержд`, `выезд`, `бригад`, `отмен`, `квитир`, `сброс`, `обработ` по всему словарю значений даёт **0 совпадений**. Все 8 файлов журнала содержат ровно 6 колонок.

Без этого невозможно измерить заявленный в ТЗ эффект «снижение ложных тревожных выездов»: нет знаменателя.

Просим: выгрузку из АРМ диспетчера за любые 3–6 месяцев, пересекающиеся с журналом: время создания карточки, время квитирования, отметка «выезд / без выезда», классификатор закрытия. Достаточно по 2–3 объектам.

Пока работаем так: реализуем справочник причин и форму фиксации решения внутри нашего сервиса — это закрывает требование раздела 12 ТЗ и создаёт механизм накопления разметки с первого дня работы.

4. График плановых работ (ППР)

86,19 % отказных событий приходятся на «массовые» дни, когда в отказ одновременно уходят десятки каналов одной базы. Из них 85 % — в рабочие часы 09:00–18:00, и только 5,74 % в выходные (при доле выходных в календаре 28,6 %). Это характерный след работы бригад, а не отказов оборудования.

Без внешнего признака «на объекте шли работы» модель будет предсказывать график бригад.

Просим: график ППР за 2024–2025 по объектам и датам, регламент проверок АПС (периодичность и окно проведения).

Пока работаем так: определяем «массовый день» эвристикой из данных (≥ 20 каналов базы в отказе либо ≥ 50 % каналов базы, в рабочие часы будня) и выносим такие события в отдельную категорию.

5. Событие 30.04 – 07.06.2021 на базе 847

За 54 суток 77 дымовых каналов выдали **1 035 783 тревоги** `Неисправен` — это 42 % всех тревог за все 7,5 года данных. Почасовое распределение плоское (размах 4,5 %), разброс между каналами 1,5 %. В 2022 году та же группа каналов дала 800 событий.

Просим: подтвердить, что это было — реальный инцидент, плановые работы или отказ шлейфа пожарной сигнализации.

Пока работаем так: помечаем окно как технический артефакт, исключаем из обучения и из расчёта норм; дополнительно используем как проверочный кейс.

Блок 2. Важно — влияет на корректность выводов

6. Значение «Затоплен» у каналов типа «Состояние насоса»

Это затопленный приямок (гидрология) или бит в слове неисправности контроллера?

Данные указывают на второе: 97,5 % таких событий приходят в пределах 5 секунд от предыдущего события того же канала; в 85,6 % случаев им предшествует Неисправен, в 65,1 % следом идёт Обесточен; сезонный пик приходится на август, а не на паводок.

Пока работаем так: не используем как признак подтопления. Подтопление детектируем по частоте пусков насосов, а «Затоплен» трактуем как код неисправности оборудования.

7. Значение «Не замкнут» у датчиков затопления

Почему в словаре этих датчиков нет значений Замкнут или Затоплен? Все 25 каналов за 8 лет дали 12 424 события (0,004 % журнала), причём Не замкнут имеет медианную и 90-процентильную длительность 0 минут, а пики приходятся на июль и октябрь, а не на паводок.

Пока работаем так: исключаем эти 25 каналов из модели подтопления, оставляем только как признак наличия оборудования.

8. Единицы измерения газовых датчиков

Какова единица измерения и аварийный порог? Наблюдаемые значения: медиана 0,01, 95-й процентиль 0,09, 99-й — 0,20, максимум 10,23. При этом текстовое Обнаружен газ приходит, судя по всему, с отдельного дискретного выхода и с числом не коррелирует.

Пока работаем так: оперируем перцентилями сети и формулируем относительно («выше 99-го процента по всем газовым каналам»), а не в абсолютных единицах.

9. Значение «Неопределен»

7,50 млн событий на 12 566 каналах, до 6 638 каналов за одни сутки. Это потеря связи АРМ с контроллером, перезапуск сервера или штатный статус опроса?

Дополнительный вопрос: пара Норма ↔ Неопределен у типа «Тепловой датчик» составляет 99,22 % всего объёма при медианной длительности эпизода 5 секунд. Верно ли, что это служебный сигнал связи, а не показание датчика?

Пока работаем так: исключаем из целевой переменной, используем как показатель качества канала.

10. Статус «Обесточен» у типа «Состояние фазы»

За 8 лет — 1 064 438 событий на 953 каналах и **ни одной** тревоги, тогда как то же значение у насосов даёт 88,9 % тревог. Отключение питания отслеживается другой системой, считается штатным переключением вводов, или это особенность настройки АРМ?

Отдельно: 107 из 957 каналов этого типа проводят в состоянии «Обесточен» более половины всего времени. Это штатный режим?

11. Режим опроса базы 797

55 газовых каналов этой базы дают **49,8 % всего объёма датасета** с периодом опроса 68 секунд, тогда как остальные 474 газовых канала опрашиваются раз в 400–1900 секунд.

Это другое оборудование, другая настройка, или шлюз-агрегатор, отдающий поток за несколько точек?

Блок 3. Полнота данных

12. Глубина данных

ТЗ (разд. 13) указывает глубину «не менее 12 лет». Фактически предоставлено 7,5 года (2019-01-01 ... 2026-06-30). Будут ли данные за 2014–2018?

13. Пропуски в сборе данных

Полностью отсутствуют сутки **2024-04-07, 2024-04-08** и **2026-06-01**; period 2024-04-06 01:01 — 2024-04-09 05:29 (76,5 часа) практически пуст.

Это реальное отключение системы, плановая миграция или потеря при выгрузке? Были ли частичные потери в другие даты?

14. Каналы без описания

В журнале присутствуют 12 627 различных каналов, из них **1 142 (9 %) отсутствуют в справочнике каналов** — у них нет ни типа датчика, ни инженерной системы, ни тега. На них приходится 9 439 854 события и 151 740 тревог.

Просим: *дополненный справочник каналов.*

15. Реестр оборудования, заявки, метео- и геоданные

ТЗ упоминает их как источники данных (разд. 6, 7, 10, 13), но в датасете они отсутствуют:

- реестр оборудования (люки, вентиляхты, камеры, насосы, вентиляторы) — нет; насосы и вентиляторы существуют только как каналы состояния, без инвентарных номеров, моделей, дат ввода и паспортного ресурса
- журнал заявок и их статусы — нет
- метеоданные — нет
- геоданные (GeoJSON / WKT, координаты, адреса) — нет ни одного поля

Просим: *подтвердить, предоставляются ли эти источники, и если да — в какой схеме.*

Пока работаем так: строим суррогатный реестр оборудования из поведения каналов; вместо географической карты используем линейную схему коллектора по пикетам (пикет разбирается для 92,1 % каналов) — это штатная система координат эксплуатационника.

Блок 4. Расхождения со схемой из Приложения 1 ТЗ

16. Структура журнала

Приложение 1 ТЗ	Фактически
ИД записи журнала	ид_события — не уникален, 6 026 078 дублей (1,92 %)

Приложение 1 ТЗ	Фактически
ИД канала данных	ид_канала_данных
ИД типа канала данных	отсутствует
Текущее значение (25 , 00)	значение_датчика — текстовое, 28,2 % значений нечисловые
Дата записи (единое поле)	разделено на дата и время
—	добавлено поле тревожное

По дублям `ид_события` : 3 792 870 идентификаторов переиспользованы **между разными годами** и указывают на разные события. Например, 1555467403 — это и (канал 3077, 2019-08-26 07:33:25, «Движения нет»), и (канал 196789, 2020-12-04 22:58:20, «0.01»).

***Просим:** подтвердить, что `ид_события` — сквозной счётчик исходной системы, переиспользуемый между партиями выгрузки, и что составной ключ является корректным решением.*

17. Справочник типов каналов

ТЗ описывает реестр типов с числовыми идентификаторами (2 = contact-unlock-norm, 4 = smoke, 6 = gas, 12 = temperature и т. д.). В датасете его нет — вместо 9 типов используются 19 текстовых значений. Тип 2 расщеплён на пять разных (КД Дверь, КД АВ, КД Люк, 9-секционный люк, Стекло). Шесть типов не имеют аналога в ТЗ: Состояние УИР-Р (762 канала), Тепловой датчик (472), Ручной извещатель (130), ИБП (80), Состояние охраны (47).

***Просим:** реестр типов с числовыми идентификаторами, если он существует.*

18. Формат тега

ТЗ описывает тег вида `МК-1.1.1.1.1.1` с шестью уровнями. Фактически ни один из 11 485 тегов не имеет префикса `МК-`, а глубина переменная: 5 сегментов у 92,4 % каналов, 6 у 5,1 %, 4 у 2,4 %, 2 у 0,16 %.

Кроме того, корневая запись справочника объектов (`ид_объект` = 5773, «Район по эксплуатации») ссылается на родителя 3831, которого в файле нет — дерево объектов является фрагментом.

***Просим:** описание правил формирования тега и полное дерево объектов.*

Блок 5. Организационное

19. Обезличивание СНЯТО обновлением от 16.09.2026

В обновлённом справочнике реальные названия восстановлены (364 строки). Исходим из того, что показ разрешён.

Обезличивание применено непоследовательно: в справочнике объектов названия заменены греческими буквами, но в названиях датчиков сохранились реальные московские топонимы (31 канал по 16 базам).

***Просим:** подтвердить, допустим ли показ этих названий в интерфейсе.*

Пока работаем так: в интерфейсе выводим обезличенные обозначения («база 847, ПК231»).

20. Целевые показатели качества

ТЗ (разд. 9) оставляет целевые Precision и Recall на этап проектирования. С учётом отсутствия разметки инцидентов предлагаем следующий набор и просим подтвердить его приемлемость:

1. **Прогноз отказа оборудования** — Precision / Recall / PR-AUC на отложенной по времени выборке.
Здесь разметка фактическая (1,5 млн событий неисправности), метрики честные.
2. **Подавление шума** — доля сокращения потока карточек при сохранении редких событий, с расшифровкой, что именно подавлено.
3. **Детекторы пожара, подтопления и проникновения** — precision@k на экспертной разметке и показатель нагрузки на диспетчера (сигналов в сутки), поскольку эталонной разметки нет.
4. **Проверка на отложенных данных** — предоставленный файл `журнал_событий_пример.csv` содержит сутки 2026-08-01, то есть на 32 дня позже конца обучающих данных. Планируем использовать его как контрольную выборку: обучение по 2026-06-30, прогноз, сравнение с фактом.

Контакт для ответов: команда готова к созвону для уточнения любого пункта.