

ОБНОВЛЕНИЕ ДАТАСЕТА ОТ 16.09.2026

Сервис прогнозирования инцидентов в инженерных коллекторах

Задача №8 «Город»

Конкурс «Лидеры цифровых трансформаций 2026»

Постановщик: Департамент жилищно-коммунального хозяйства города Москвы

Эксплуатант: АО «Москоллектор»

Команда «Дискреция творца»

Москва, сентябрь 2026

Содержание

1. Что изменилось — проверено побайтово	2
2. Главное: добавлена колонка <code>ид_объект</code>	2
2.1. Проверка на независимом эталоне — сошлась точно	3
2.2. Структура связей оказалась чище ожидаемой	3
3. Побочное изменение: восстановлены реальные названия	3
4. Карта наблюдаемости — теперь по объектам	4
5. Что обновление НЕ закрыло	5
6. Что меняется в плане разработки	5
7. ETL-ловушка усугубилась	5
8. Состояние файлов	6

Проверен обновлённый `dataset.zip` (16.09.2026 22:37). Старая распакованная версия сохранена в `dataset/` для сличения; из архива извлечён только изменившийся файл.

1. Что изменилось — проверено побайтово

Сверка CRC32 каждого файла архива с распакованной старой версией:

Файл	Вердикт
<code>ext-journal-2019...2026.7z</code> (все 8)	идентичны
<code>журнал_событий_пример.csv</code>	идентичен
<code>справочник_объектов_диспетчер.csv</code>	идентичен
<code>справочник_каналов_датчиков.csv</code>	изменён (1 260 877 → 1 321 317 байт)

Заявление организаторов подтверждается: тронут ровно один файл.

Практическое следствие: 313 546 016 событий не изменились, перекодировка Parquet не нужна, все находки аудита по значениям, тревогам, отказам, сезонности и временным паттернам остаются в силе. Пересмотра требует только то, что касалось локации.

2. Главное: добавлена колонка `ид_объект`

Это закрывает **критичный блокер № 1** — отсутствие связи «канал → объект», из-за которого три метода восстановления были проверены и провалены.

Показатель	Значение
Строк в справочнике	11 485 (не изменилось)
Каналов без объекта (NULL)	0
Различных <code>ид_объект</code>	78
Из них существуют в справочнике объектов	78 из 78
Покрытие событий журнала	96,99 % (304 106 162 из 313 546 016)

Ссылочная целостность полная. Каналы привязаны к уровню L3 (подобъекты) — самому детальному из официальной иерархии.

2.1. Проверка на независимом эталоне — сошлась точно

Аудит до обновления восстановил две связи собственными методами. Обе подтвердились:

Эталон аудита	Официальные данные	Итог
база 847 = объект Кси	все 5 подобъектов под родителем 5327 «объект Кси»	
база 885 = объект Дзета, 128 каналов	«объект Дзета ДУ», ровно 128 каналов	
база 890 = объект Дзета, 440 каналов	Дзета ПС 341 + ОС 77 + шкафы 14 + щит 8 = ровно 440	
885 — диспетчерская, 890 — пожарно-охранная	885 = «ДУ», 890 = «ПС»/«ОС»	

Совпадение вплоть до отдельных чисел означает, что новой колонке можно доверять, а методика аудита была корректной.

2.2. Структура связей оказалась чище ожидаемой

- **30 баз тега из 32** отображаются ровно в **один** объект L2 — гипотеза «база ≈ коллектор» верна
- Исключения всего два: база 798 (164 канала, объекты 6 и 12) и база 163 (45 каналов, объекты 15 и 4356)
- На один объект L2 приходится от 1 до 5 баз

Карта объектов верхнего уровня:

Объект L2	Баз	Подобъектов	Каналов
объект Мю	2	5	1 487
объект Кси	1	5	1 459
объект Тау	1	3	1 209
объект Эпсилон	5	10	1 110
объект Гамма	3	4	1 088
объект Каппа	2	4	1 040
объект Зита	5	12	751
Комплекс объект Дельта	1	3	622
ПС объект Омега	2	4	610
объект Бета	2	4	421
ПС объект Ро	2	4	389
объект Альфа	2	5	383
объект Вита	2	4	327
объект Омикрон	2	4	302
объект Йота	1	4	212
объект Сигма	1	3	75

База 797, дающая 52 % всего объёма журнала, принадлежит объекту Альфа (преимущественно подобъекту «ДУ объект Альфа», 164 канала). Перекос теперь локализован: половина датасета — это газовая телеметрия одного объекта.

3. Побочное изменение: восстановлены реальные названия

В 364 строках изменилось поле `название_датчика`. Типы датчиков, инженерные системы и теги не тронуты ни в одной строке.

Прежнее обезличивание **портило названия**, вырезая подстроки-топонимы и оставляя обрубки. Теперь названия восстановлены целиком:

Было	Стало
ОХР союзный	ОХР Профсоюзный
ОС Пл. ина	ОС Пл. Гагарина
[Охранная зона]ережная	[Охранная зона]Андреевская набережная
АНС ПК51 Н1	АНС Донской ПК51 Н1
КД дверь сопр. ПК70 с	КД дверь сопр. ПК70 с Зелинского
Д22-32 ПК2-ПК61 .т.	Д22-32 ПК2-ПК61 Гагар.т.

Распределение правок по базам: 797 — 146, 418 — 81, 798 — 38, 15 — 24, 163 — 19, 16 — 19, 257 — 11, 890 — 10, остальные — по 1–7.

Следствие: вопрос о допустимости показа топонимов снимается — организаторы сами внесли реальные московские названия в официальный датасет. Ранее принятое решение выводить обезличенные подписи следует пересмотреть: теперь к-р Донской, ПК51 не нарушает условий, а диспетчеру информативнее греческой буквы.

4. Карта наблюдаемости — теперь по объектам

Связь с объектами позволила построить то, чего раньше не было: честную карту «где мы слепы».

Объект	Насосы	Затопление	Тепловые	Дым	Газ
объект Кси	15	0	0	933	55
объект Мю	8	6	0	909	40
объект Гамма	11	2	0	589	26
объект Каппа	6	4	0	571	33
объект Эпсилон	20	1	0	471	96
объект Зита	13	3	0	331	48
Комплекс объект Дельта	5	6	0	177	62
объект Тау	30	0	339	96	8
объект Альфа	11	2	0	88	55
ПС объект Омега	21	0	62	72	8
ПС объект Ро	8	0	0	52	35
объект Бета	1	1	71	22	4
объект Омикрон	13	0	0	11	41
объект Вита	14	0	0	9	6
объект Йота	0	0	0	3	11
объект Сигма	4	0	0	3	1

Ключевые выводы подтвердились на уровне объектов:

- **Тепловые датчики есть только на 3 объектах из 16.** На остальных 13, включая объект Кси с 933 дымовыми каналами, подтвердить задымление температурой физически нечем
- **Датчики затопления отсутствуют на 8 объектах из 16,** а где есть — их 1–6 штук
- **объект Йота не имеет ни одного насоса** — сценарий подтопления там неприменим

Это ровно тот материал, который нужен продуктовому принципу «честная граница наблюдаемости»: вердикт по объекту Кси обязан говорить «тепловых датчиков на объекте нет», а не «температура в норме».

5. Что обновление НЕ закрыло

Блокер	Статус
1 142 канала журнала без паспорта (9,44 млн событий, 3,01 %)	остался — справочник по-прежнему не содержит эти каналы
Семантика флага <code>тревожное</code> и его дрейф	остался
Журнал решений диспетчера / ground truth	остался
График ППР	остался
Событие мая 2021 на базе 847	остался
Смысл <code>Затоплен</code> , <code>Не замкнут</code> , <code>Неопределен</code> , единицы газа	остались
Глубина 7,5 года вместо 12	остался
Провалы сбора 2024-04-06...09 и 2026-06-01	остался
Геоданные (координаты, GeoJSON/WKT)	остались отсутствовать
Реестр оборудования, заявки, метеоданные	остались отсутствовать
Расхождения со схемой Приложения 1 ТЗ	остались

Из 20 вопросов письма закрыт **один** (№ 1, самый критичный) и де-факто снят **один** (№ 19, топонимы). Остальные 18 сохраняют актуальность.

6. Что меняется в плане разработки

1. **Локация переходит на официальную иерархию.** Единица — `ид_объект` (L3, 78 значений), с разворотом до L2 и детализацией пикетом. Суррогат (`база`, `ПК`) больше не нужен как основа, остаётся как уточнение внутри объекта.
2. **Требование ТЗ «определение локации оборудования» выполнимо** для 96,99 % событий.
3. **«Интерактивная карта»** становится деревом объектов (район → 16 объектов → 78 подобъектов) плюс линейная схема по пикетам. Географических координат по-прежнему нет.
4. **Агрегация модели** — на уровне L3, потому что L2 склеивает разные коллекторы (объект Зита содержит 12 подобъектов от 5 баз).
5. **Карта наблюдаемости** становится отдельной ценностью продукта и показывается в интерфейсе.
6. **Флаг `SHOW_TOPONYMS`** предлагается включить по умолчанию — ограничение отпало.

7. ETL-ловушка усугубилась

Справочник каналов использует CRLF и содержит переводы строк **внутри** поля `название_датчика`. Восстановление длинных названий увеличило их количество:

Версия	Физических строк	Логических записей	Строк-продолжений
v1 (старая)	11 495	11 485	9
актуальная	11 517	11 485	31

Загрузчик на `split('\n')` или `pandas` с неверным `quoting` даст 11 516 строк вместо 11 485 и потеряет тип у 31 канала. Требование ТЗ — открытый воспроизводимый код, поэтому параметры чтения (`quotechar='\"'`, `CRLF`, `encoding='utf-8'`) должны быть явно указаны в инструкции по сборке, а число загруженных записей — проверяться ассертом `== 11485`.

8. Состояние файлов

Переход на актуальную версию выполнен:

Файл	CRC32	Статус
dataset/справочник_каналов_датчиков.csv	52b7a8ce	актуальная версия, совпадает с архивом
dataset/справочник_каналов_датчиков.v1.csv	1f636ff1	прежняя версия, сохранена для сличения

Проверка после переноса: 11 485 строк, 11 485 уникальных каналов, у всех заполнен `ид_объект`, 78 различных объектов, 0 битых ссылок на справочник объектов.

Остальные файлы датасета не трогались — они байт-в-байт совпадают с архивом.